

Cosignes pour le projet final du module

Apprentissage Statistique Appliqué

Le travail doit être réalisé en binôme. Dans des cas exceptionnels, il sera autorisé de faire le travail à trois, mais les attentes seront alors plus élevées.

Le travail consiste à choisir un jeu de données qui vous intéresse et d'appliquer des méthodes de l'apprentissage automatique et de visualisation de données vues en cours et en TP.

Les données

- Choisissez un jeu de données qui vous intéresse. Il faut que vous le compreniez et que vous puissiez expliquer pourquoi l'utilisation de méthodes d'apprentissage automatique est pertinente sur ces données.
- Évitez les jeux de données trop simples ou trop utilisés dans les cours, comme MNIST, Iris, Boston Housing, etc.
- Les données doivent contenir au moins une dizaine de variables (*features*) et au moins 500 observations.
- Il faut que la tâche de prédiction supervisée soit pertinente pour ces données.
- Vous pouvez trouver des données sur le site <https://archive.ics.uci.edu/>.

Les méthodes

- Effectuez un prétraitement (*pre-processing*) des données si nécessaire.
- Expliquez clairement le critère utilisé pour évaluer les résultats et sa pertinence.
- Utilisez au moins 4 méthodes de prédiction, dont :
 - au moins une méthode interprétable,
 - une méthode ensembliste,
 - une méthode basée sur les réseaux de neurones.
- Utilisez principalement les méthodes vues en cours, mais vous pouvez en ajouter d'autres en justifiant leur pertinence.

Les livrable

Pour le 9 janvier 2026, vous devrez soumettre, via le lien dédié :

- un rapport de 5 pages maximum,
- un fichier Notebook exécutable sur Google Colab permettant d'obtenir les résultats décrits dans le rapport.

Le rapport

- ❖ Rédigez en anglais ou en français. Soyez clairs et concis.
- ❖ Vous pouvez utiliser des outils d'IA pour améliorer vos phrases, mais évitez que le texte soit entièrement généré par ces outils (cela se remarque facilement et sera sanctionné).

- ❖ Insérez des graphiques et des tableaux esthétiques. Chaque graphique et tableau doit faire l'objet d'une discussion dans le rapport.
- ❖ N'incluez pas de code dans le rapport.
- ❖ Si vous incluez des formules mathématiques, écrivez-les en LaTeX et expliquez toutes les notations .
- ❖ Format du rapport :
 - 5 pages maximum,
 - uniquement au format PDF,
 - police de taille 12.
- ❖ Les rapports plus courts ne seront pas pénalisés : c'est le contenu qui compte, pas le volume.
- ❖ Évitez les images en haute résolution (idéalement, le fichier doit faire moins de 1 Mo).
- ❖ Donnez un titre à votre projet et indiquez vos noms sur la première page.
- ❖ Si une partie de ce projet a été (ou sera) utilisée pour un autre cours, dites le clairement.

Le code

- ❖ Limitez l'utilisation d'outils d'IA pour générer le code. Inspirez-vous des TP et adaptez le code en conséquence.
- ❖ Découpez votre code en cellules logiques et ajoutez des cellules de texte pour expliquer le rôle de chaque partie de code.
- ❖ Ajoutez des commentaires pour clarifier le code.

Dates importantes

- **15 novembre 2025** : date limite pour constituer les groupes. Informez-m'en en remplissant le formulaire : <https://forms.gle/TWM2zZhrzZMMFZW47>.
- **30 novembre 2025** : date limite pour choisir le jeu de données. Informez-m'en en remplissant le formulaire : <https://forms.gle/bT4oUQ2wR94Mm7JU6>.
- **07 décembre 2025** : date limite pour choisir l'heure de présentation (10 minutes + 5 minutes de questions/discussion). Choisissez un créneau dans ce tableau : https://docs.google.com/spreadsheets/d/1G4BhHVMlj24L1q_OQYMX430KKsuh1eAOQ4YUQasNJt8/edit?usp=sharing.
- **9 janvier 2026** : date limite pour déposer le rapport via le formulaire : <https://forms.gle/2CC23Gpvk6ticKqE6>.