

Projet d'Applied Statistical Learning : Prédiction du genre musical à partir des features audio sur Spotify

Mathieu Lang, Hugo Lecointre

December 2025

Contents

1	Introduction	2
1.1	Présentation du Dataset	2
1.2	Première exploration	3
2	Premier modèle : Régression logistique multinomiale	4
3	Deuxième modèle : Random Forest	5
4	Troisième modèle : XgBoost	6
5	Quatrième modèle : Réseau de neurones	6
6	Conclusion	6
6.1	Perspectives et améliorations futures	6

1 Introduction

1.1 Présentation du Dataset

Le jeu de données utilisé dans ce projet provient de Spotify (le dataset a été téléchargé sur Kaggle) et regroupe des informations détaillées sur des titres musicaux, combinant à la fois des données descriptives (artiste, album, popularité) et des caractéristiques audio numériques extraites automatiquement par Spotify. Chaque observation correspond à un morceau et est associée à un genre musical, qui constitue la variable cible du projet. Concernant la structure des données, le dataset contient 114 000 titres pour 21 variables décrivant chaque morceau : des informations d'identification, des données générales, des caractéristiques audio continues ainsi que des caractéristiques musicales discrètes. La variable cible est le genre musical `track_genre`.

L'objectif de ce projet est de prédire le genre musical d'un morceau à partir de ses caractéristiques audio et de ses données, en formulant le problème comme une tâche de classification supervisée multi-classes. Afin d'évaluer différentes approches de modélisation, nous étudierons et comparerons quatre modèles. Chacun de ses modèles apportent une vision différente sur la structure des données et les relations entre les variables explicatives et la variable cible.

Dans un premier temps, nous utiliserons une régression logistique. Ce modèle constitue une référence de base en classification supervisée : il est simple, rapide à entraîner et facilement interprétable. Il permet d'évaluer la séparabilité linéaire des genres musicaux et d'identifier l'importance relative des variables explicatives, servant ainsi de point de comparaison pour les modèles plus complexes.

Dans un second temps, nous mettrons en œuvre un réseau de neurones de type Multi-Layer Perceptron (MLP). Ce modèle permet de dépasser les limites linéaires de la régression logistique en capturant des relations non linéaires entre les caractéristiques audio. Il est particulièrement adapté lorsque les frontières de décision entre classes sont complexes, ce qui est souvent le cas dans les données musicales.

Dans un troisième temps, nous emplyerons une Random Forest. Cette dernière est particulièrement adaptée à notre problème de classification des genres musicaux car elle permet de modéliser des relations non linéaires complexes entre les caractéristiques audio ainsi que leurs interactions. En

agrégeant un grand nombre d'arbres de décision entraînés sur des sous-échantillons aléatoires des données et des variables, elle réduit la variance et se montre robuste au bruit présent dans les labels de genre (un morceau peut appartenir à plusieurs genres). De plus, ce modèle nécessite peu de prétraitement et fournit des mesures d'importance des variables, offrant ainsi un bon compromis entre performance prédictive et interprétabilité.

Enfin nous utiliserons XGBoost. Ce modèle repose sur une approche de gradient boosting dans laquelle les arbres sont construits de manière séquentielle afin de corriger progressivement les erreurs des modèles précédents. Cette stratégie permet de capturer des interactions complexes entre les caractéristiques audio, souvent déterminantes pour distinguer des genres musicaux proches. Grâce à ses mécanismes de régularisation avancés (L1, L2) et à un contrôle précis de la complexité du modèle (profondeur des arbres, taux d'apprentissage...). XGBoost limite le sur-apprentissage tout en atteignant d'excellentes performances sur des données tabulaires. Il constitue ainsi une référence haute performance pour la comparaison finale des modèles étudiés dans ce projet.

1.2 Première exploration

Le jeu de données étant relativement propre dès l'origine, nous commençons directement par une analyse statistique descriptive des variables afin d'identifier d'éventuelles valeurs aberrantes ou incohérentes.

Par exemple, l'examen de la variable `duration_ms` révèle des durées pouvant atteindre 5 millions de millisecondes, soit environ 83 minutes. Ces valeurs correspondent davantage à des podcasts qu'à des morceaux musicaux standards. Nous choisissons donc de les exclure du jeu de données en plafonnant la durée maximale d'un morceau à 15 minutes, soit 900 000 ms. Ce seuil, bien que subjectif, permet de conserver l'essentiel des titres musicaux tout en éliminant des observations non pertinentes pour notre tâche de classification.

Nous nous intéressons ensuite à la variable cible, `track_genre`. Le dataset initial contient 114 genres musicaux distincts, ce qui rend la tâche de classification multi-classes particulièrement complexe et peu interprétable. Afin de rendre le problème plus "faisable", nous procédons à un regroupement de genres musicalement proches, aboutissant à 12 catégories finales : Pop, Rock/Metal, Hip-Hop, Electronic, R&B/Soul/Funk, Jazz/Blues, Classical, Country/Folk, Latin/World, Reggae/Ska, Asian Pop et Ambient/Chill.




Figure 1: Fréquence classe

Nous analysons ensuite les proportions de chaque genre afin d'évaluer la distribution des classes (cf Figure 1). Cette étape est cruciale, notamment pour la séparation des données en ensembles d'entraînement et de test, pour laquelle nous utiliserons une stratification afin de préserver les proportions relatives des classes. L'analyse met également en évidence un déséquilibre entre les classes, qui devra être pris en compte lors de la modélisation. En effet ce déséquilibre entre les genres peut biaiser l'apprentissage des modèles en favorisant les classes majoritaires au détriment des classes minoritaires. Afin de limiter l'impact du déséquilibre des classes, plusieurs stratégies seront envisagées. D'une part, nous utiliserons des métriques d'évaluation adaptées, telles que le F1-score macro ou la balanced accuracy, plutôt que la seule accuracy. D'autre part, certains modèles permettront l'utilisation de poids de classes afin de pénaliser davantage les erreurs sur les classes minoritaires. Enfin, nous analyserons les matrices de confusion afin d'évaluer finement les performances par genre.

2 Premier modèle : Régression logistique multinomiale

Le modèle atteint 39% d'accuracy mais cette performance est trompeuse. La macro-F1 très faible montre qu'il échoue à prédire plusieurs classes, certaines n'étant jamais prédites. Le modèle est fortement biaisé vers les classes majoritaires, ce qui indique un problème de déséquilibre et probablement de représentation des classes minoritaires.

Après équilibrage, le modèle devient plus juste entre les classes : toutes sont

désormais prédites, le rappel macro augmente, mais au prix d’une baisse de l’accuracy. Enfin j’ai testé une régularisation forte pour réduire la variance, mais les performances restent inchangées. Cela indique que la régression logistique atteint une limite de capacité : les frontières linéaires ne suffisent pas à séparer correctement les classes et qu’un modèle non linéaire serait plus adapté.

3 Deuxième modèle : Random Forest

Modèle	Accuracy	F1 macro	Commentaire
RF baseline	0.566	0.46	Bon compromis global
RF équilibré	0.550	0.47	Meilleur pour classes rares
RF optimisé	0.568	0.46	Meilleur score global

Table 1: Comparaison des performances des différentes variantes de Random Forest

Le tableau 1 compare les performances des trois variantes de Random Forest évaluées.

Le modèle de base atteint une accuracy de 56.6% et constitue un compromis satisfaisant entre performance globale et stabilité.

L’équilibrage des classes ne conduit pas à une amélioration significative de l’accuracy (55.0%), mais permet une légère progression du F1-score macro (0.47), traduisant une meilleure prise en compte des classes minoritaires, en particulier le hip-hop.

Le Random Forest optimisé obtient la meilleure accuracy globale (56.8%), sans toutefois améliorer les performances macro par rapport au modèle de base.

Dans l’ensemble, les trois configurations présentent des performances similaires, avec de bons résultats sur les genres majoritaires disposant de signatures audio marquées (electronic, rock, latin), tandis que les genres minoritaires ou hybrides (hip-hop, reggae, rnb) restent difficilement identifiables. Ces résultats suggèrent que les limites observées sont davantage liées à la représentation des genres musicaux à partir des seules caractéristiques audio qu’au choix du modèle ou au réglage des hyperparamètres.

4 Troisième modèle : XgBoost

XGBoost obtient les meilleures performances globales du projet avec une accuracy proche de 58% et un F1-score macro de 0.48. Une recherche légère d'hyperparamètres par validation croisée ne conduit pas à une amélioration significative des résultats, les performances restant comparables à celles du modèle non optimisé. Cette stabilité suggère que XGBoost est déjà proche de son optimum sur ce jeu de données et que les limites observées sont principalement liées à la faible séparabilité de certains genres musicaux à partir des seules caractéristiques audio.

5 Quatrième modèle : Réseau de neurones

hhhh

6 Conclusion

6.1 Perspectives et améliorations futures

Les performances obtenues avec des modèles tabulaires tels que Random Forest et XGBoost semblent atteindre un plafond, suggérant que les principales limites du projet sont davantage liées à la représentation des données qu'au choix du modèle. Une première piste d'amélioration consisterait à enrichir les caractéristiques utilisées, notamment en intégrant des informations textuelles issues des paroles. Ces sources pourraient améliorer la discrimination de genres culturellement définis ou hybrides, tels que le hip-hop, le reggae ou le R&B.

Par ailleurs, la reformulation du problème de classification pourrait conduire à des évaluations plus réalistes. Des métriques telles que la top- k accuracy ou une approche multi-label permettraient de mieux prendre en compte le chevauchement naturel entre genres musicaux. Ces pistes constituent des extensions naturelles du travail présenté et pourraient conduire à des gains significatifs de performance.